

# **Vorlesung Mathematische Statistik**

**Wintersemester 2018/2019**

Vorlesung: Prof. Dr. Dietmar Ferger  
Mitschrift: Willi Sontopski

11. Oktober 2018

# Inhaltsverzeichnis

<b>1. Einführung</b>	<b>2</b>
1.1. Der Median	2
<b>A. Anhang</b>	<b>9</b>
A.1. Grundlagen, die man kennen sollen	9

# 1. Einführung

Viele Schätzer in der Statistik sind definiert als Minimal- oder Maximalstelle von bestimmten *Kriteriumsfunktionen*, z. B. der *Maximum-Likelihood-Schätzer (MLS)* oder *Minimum-Quadrat-Schätzer (MQS, KQS)* oder *Bayes-Schätzer*. Allgemein nennt man solche Schätzer **M-Schätzer**.

Ziel: Untersuchung des asymptotischen Verhaltens ( $n \rightarrow \infty$ ) von M-Schätzern über einen *funktionalen Ansatz*. Als Beispiel:

## 1.1. Der Median

Sei  $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow \mathbb{R}$  eine reelle Zufallsvariable mit Verteilungsfunktion  $F_X : \mathbb{R} \rightarrow [0, 1]$ ,  $F_X(x) := \mathbb{P}[X \leq x]$ , also  $X \sim F_X$ . Definiere

$$\begin{aligned} Y(t) &:= \mathbb{E}(|X - t|) & (1.0) \\ &= \int_{\Omega} |X(\omega) - t| \, d\mathbb{P}(\omega) \\ &\stackrel{\text{Trafo}}{=} \int_{\mathbb{R}} |x - t| \left( \mathbb{P} \circ X \, dx \right) \\ &= \int_{\mathbb{R}} |x - t| (F \, dx) \quad \forall t \in \mathbb{R} \\ m &:= \arg \min_{t \in \mathbb{R}} Y(t) := \text{(irgendeine) Minimalstelle der Funktion} \end{aligned}$$

**Notation.**  $F(m-) := F(m - 0) := \lim_{t \uparrow m} F(t)$

Charakterisierung der Menge aller Mediane in folgendem kleinen Lemma:

**Lemma 1.1.1** Sei  $X \sim F_X$  integrierbar und  $m \in \mathbb{R}$ . Dann äquivalent:

- (a)  $F(m-) \leq \frac{1}{2} \leq F(m)$
- (b)  $\mathbb{E}[|X - t|] \geq \mathbb{E}[|X - m|] \quad \forall t \in \mathbb{R}$
- (c)  $m$  ist Median

Beweis. Zeige (a)  $\Rightarrow$  (b):

Setze  $h(t) := \mathbb{E}[|X - t| - |X - m|] \stackrel{\text{Lin}}{=} Y(t) - Y(m)$ . Dann ist 2. äquivalent zu  $h(t) \geq 0 \forall t \in \mathbb{R}$ . Dies ist noch zu zeigen.

Fall 1:  $t < m$

$$\begin{aligned}
h(t) &\stackrel{\text{Trafo}}{=} \int_{\mathbb{R}} |x - t| - |x - m| Q_F(\mathrm{d}x) \\
&= \int_{(-\infty, t]} \underbrace{|x - t| - |x - m|}_{=t-x-(m-x)=-(m-t)} F(\mathrm{d}x) + \int_{(t, m)} \underbrace{|x - t| - |x - m|}_{\substack{x-t \geq 0 \\ m-x \leq m-t \\ \geq -(m-t)}} F(\mathrm{d}x) + \int_{[m, \infty)} \underbrace{|x - t| - |x - m|}_{x-t-(x-m)=m-t} F(\mathrm{d}x) \\
&\geq -(m-t) \cdot \underbrace{Q((-\infty, t])}_{F(t)} + \left( -(m-t) \cdot F(m-) - F(t) \right) + (m-t) \cdot \underbrace{Q([m, \infty))}_{1 - \underbrace{Q((-m, m))}_{F(m-)}} \\
&= - \underbrace{(m-t)}_{\geq 0} \cdot \underbrace{(1 - 2 \cdot F(m-))}_{\stackrel{!}{\geq 0}} \\
&\geq 0
\end{aligned}$$

Fall 2:  $t > m$

$$\begin{aligned}
h(t) &= \int_{(-\infty, m]} \dots F(\mathrm{d}x) + \int_{(m, t]} \dots + \int_{(t, \infty)} \dots F(\mathrm{d}x) \\
&\dots \\
&\geq (t-m) \cdot \underbrace{(2 \cdot F(m) - 1)}_{\stackrel{!}{\geq 0}} \\
&\geq 0
\end{aligned}$$

Fall 3:  $t = m$  ist trivial. #

Zeige (b)  $\Rightarrow$  (a):

Nach Annahme ist  $h(t) \geq 0 \forall t \in \mathbb{R}$ .

Fall 1:  $t < m$  Die obige Rechnung im Fall 1 bei 1.  $\Rightarrow$  2. zeigt:

$$\begin{aligned}
0 \leq h(t) &= -(m-t) \cdot F(t) + \int_{(t,m)} \underbrace{x - t - (m-x)}_{=2x-t-m \leq m-t} F(\mathrm{d}x) + (m-t) \cdot (1 - F(m-)) \\
&\leq -(m-t) \cdot \left( F(t) - 1 + \underbrace{F(m-) - F(m-)}_{=0} + F(t) \right) \\
&= \underbrace{(m-t)}_{>0} \cdot (1 - 2 \cdot F(t)) \\
&\implies \forall t < m : 0 \leq (m-t) \cdot (1 - 2 \cdot F(t)) \\
&\implies \forall t < m : 0 \leq 1 - 2 \cdot F(t) \\
&\implies \forall t < m : F(t) \leq \frac{1}{2} \\
&\xrightarrow{t \uparrow m} F(m-) \leq \frac{1}{2}
\end{aligned}$$

Fall 2:  $t > m$  Siehe 2. Fall, analog.

Zeige (a)  $\Leftrightarrow$  (c): (b) ist offensichtlich äquivalent zur Definition des Medians.  $\square$

### Bemerkung 1.1.2

1. Lemma 1.1.1 (a) besagt, dass  $\{m \in \mathbb{R} : m \text{ erfüllt 1.}\}$  die Menge aller Mediane von  $F$  ist.
2. Im Allgemeinen gibt es mehrere Mediane. Üblicherweise wählt man  $m := F^{-1}(\frac{1}{2})$ , wobei

$$F^{-1}(u) := \inf \{x \in \mathbb{R} : F(x) \geq u\} \quad \forall u \in (0, 1)$$

die **Quantilfunktion** / die **verallgemeinerte Inverse** ist. Da

$$F(F^{-1}(u)-) \leq u \leq F(F^{-1}(u)) \quad \forall u \in (0, 1),$$

erfüllt  $m = F^{-1}(\frac{1}{2})$  die Bedingung (a) in Lemma 1.1.1 und ist somit ein Median, nämlich der kleinste.

3. Die obige Funktion (1.0), also

$$Y : \mathbb{R} \rightarrow \mathbb{R}, \quad Y(t) = \int |x - t| F(\mathrm{d}x) \quad \forall t \in \mathbb{R},$$

ist stetig (nutze Folgenkriterium + dominierte Konvergenz bzw. Satz von Lebesgue), aber im Allgemeinen nicht differenzierbar, z. B. falls  $F \sim X$  eine diskrete

Zufallsvariable ist. In diesem Fall ist somit die Minimierung über Differentiation nicht möglich!

Zur Schätzung von  $m$  seien  $X_1, \dots, X_n$  i.i.d.  $\sim F$  mit zugehöriger **empirischer Verteilungsfunktion**

$$F_n(x) := \frac{1}{n} \cdot \sum_{i=1}^n \mathbb{1}_{\{X_i \leq x\}} \quad \forall x \in \mathbb{R}.$$

Tatsächlich ist  $F_n$  die Verteilungsfunktion zum **empirischen Maß**

$$Q_n := \frac{1}{n} \cdot \sum_{i=1}^n \delta_{X_i} \text{ wobei } \delta_x \text{ das Dirac-Maß in } x \in \mathbb{R}$$

Gemäß dem Satz von Glivenko-Cantelli gilt:

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow{n \rightarrow \infty} 0 \text{ konvergiert } \mathbb{P}\text{-fast sicher für alle Verteilungsfunktionen } F$$

**Erinnerung.** Für das Dirac-Maß  $\delta_x : \mathcal{A} \rightarrow \mathbb{R}_+$ ,  $\delta_x(A) := \mathbb{1}_A(x)$  gilt:

$$\int f(t) \delta_x(dt) = f(x)$$

Ein vages Stetigkeitsargument motiviert folgenden Schätzer für  $m$ :

$$\begin{aligned} \hat{m}_n &:= \arg \min_{t \in \mathbb{R}} Y_n(t) := \text{(irgendeine) Minimalstelle der Funktion} \\ Y_n(t) &:= \int_{\Omega} |x - t| F_n(dx) \\ &= \int_{\Omega} |x - t| Q_n(dx) \\ &= \frac{1}{n} \cdot \sum_{i=1}^n \int |x - t| \delta_{X_i}(dx) \\ &= \frac{1}{n} \cdot \sum_{i=1}^n |X_i - t| \end{aligned}$$

$\hat{m}_n$  heißt **empirischer Median** von  $X_1, \dots, X_n$  mit üblicher Auswahl  $\hat{m}_n = F_n^{-1}(\frac{1}{2})$  gemäß Lemma 1.1.1 (da empirische Verteilungsfunktion eine Verteilungsfunktion ist).

**Bemerkung.**

- Wenn man eine ungerade Anzahl von Daten hat, ist der Median der mittlere Wert, nachdem man die Daten der Größe nach geordnet hat.
- Hat man hingegen eine gerade Anzahl an Daten, dann ist der Median der kleinere der beiden mittleren Werte.

Mit dem starken Gesetz der großen Zahlen (SGGZ) gilt

$$\forall t \in \mathbb{R} : \left( Y_n(t) \xrightarrow{n \rightarrow \infty} \mathbb{E}[|X_1 - t|] = Y(t) \text{ fast sicher} \right) \quad (1.1)$$

Problem: Folgt aus (1.1) bereits, dass

$$\arg \min_{t \in \mathbb{R}} Y_n(t) \xrightarrow{n \rightarrow \infty} \arg \min_{t \in \mathbb{R}} Y(t) \text{ fast sicher?}$$

Dann folgte:

$$\hat{m}_n \xrightarrow{n \rightarrow \infty} m \text{ fast sicher (starke Konvergenz)}$$

Wir formalisieren und verallgemeinern:

$$\begin{aligned} X_i : (\Omega, \mathcal{A}, P) &\rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})) \text{ messbar,} & \omega &\mapsto X_i(\omega) \\ \implies Y_n(t) &:= Y_n(t, \omega) = \frac{1}{n} \cdot \sum_{i=1}^n |X_i(\omega) - t| \\ \implies Y_n(t, \cdot) &: (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})) \text{ messbar } \forall t \in \mathbb{R} \end{aligned}$$

**Definition.** Die **Kollektion**

$$Y_n := \{Y_n(t, \cdot) : t \in \mathbb{R}\} = \{Y_n(t) : t \in \mathbb{R}\}$$

heißt **stochastischer Prozess (SP)**. Die Abbildung

$$X_n(\cdot, \omega) : \mathbb{R} \rightarrow \mathbb{R}, \quad t \mapsto Y_n(t, \omega)$$

heißt **Trajektorie / Pfad** des SP  $Y_n$  zu festem  $\omega \in \Omega$ .

In unserem Beispiel sind für alle  $\omega \in \Omega$  die Pfade stetig auf  $\mathbb{R}$ . Die Abbildung

$$Y_n : \Omega \rightarrow XC(\mathbb{R}, \mathbb{R}), \quad \omega \mapsto Y_n(\cdot, \omega)$$

heißt **Pfadabbildung** des SP  $Y_n$ . Wir identifizieren also den SP  $Y_n$  mit seiner Pfadabbildung. Damit ist  $Y_n$  eine Abbildung von  $\Omega$  in den Funktionenraum

$$C(\mathbb{R}) := C(\mathbb{R}, \mathbb{R}) := \{f : \mathbb{R} \rightarrow \mathbb{R} : f \text{ ist stetig} \}.$$

Sei  $d : C(\mathbb{R}) \times C(\mathbb{R}) \rightarrow \mathbb{R}$  die Metrik der gleichmäßigen Konvergenz der Kompakta auf  $C(\mathbb{R})$  (formale Definition kommt später) und sei

$$\mathcal{B}(C(\mathbb{R})) := \mathcal{B}_d(C(\mathbb{R})) = \sigma(\{G \subseteq C(\mathbb{R}) : G \text{ ist offen bzgl. } d\})$$

die von  $d$  induzierte **Borel- $\sigma$ -Algebra**.

Wir werden sehen, dass die Abbildung

$$Y_n : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (C(\mathbb{R}), \mathcal{B}(C(\mathbb{R})))$$

messbar ist.  $Y_n$  ist also eine Zufallsvariable mit Werten im metrischen Raum  $(C(\mathbb{R}), d)$ . Formulierung des Problems im allgemeinen Rahmen: Seien  $Y_n$ ,  $n \in \mathbb{N}$  mit  $Y$  SP mit stetigen Pfaden (stetige SP). Was lässt sich sagen über die Gültigkeit der folgenden Implikationen?

$$Y \xrightarrow{n \rightarrow \infty} Y \text{ fast sicher} \implies \arg \min_{t \in \mathbb{R}} Y(t) \xrightarrow{n \rightarrow \infty} \arg \min_{t \in \mathbb{R}} Y(t) \text{ fast sicher} \quad (1.2)$$

Ziel: Welche Art der Konvergenz  $Y_n \xrightarrow{n \rightarrow \infty} Y$  reicht für obige Implikation aus? Gleichmäßige Konvergenz, gleichmäßige Konvergenz auf Kompakta punktweise Konvergenz oder sogar nur (1.1)?

$Y$  besitzt womöglich (unter positiven Wahrscheinlichkeiten) keine eindeutige Minimalstelle. Und dann?

Für die Konstruktion von (asymptotischen) Konfidenzintervallen für  $m$  benötigt man **Verteilungskonvergenz**:

$$a_n(\hat{m}_n - m) \xrightarrow{\mathcal{L}} \xi \text{ in } \mathbb{R} \quad (1.3)$$

wobei  $a_n \rightarrow \infty$  in  $\xi$  Grenzvariable, die es zu identifizieren gilt. Für die Herleitung von (1.3) favorisiere wieder einen *funktionalen Ansatz*. Sei

$$Z_n(t) := \beta_n \cdot \left( Y_n \left( m + \frac{t}{a_n} \right) - Y_n(m) \right) \quad t \in \mathbb{R}$$

der sogenannte **reskalierte Prozess** zu  $Y_n$ , wobei  $\beta_n$  eine geeignete positive Folge ist. Damit folgt

$$a_n(\hat{m}_n - m) = \arg \min_{t \in \mathbb{R}} Z_n(t) \quad (1.4)$$

Klar:  $Z_n$  ist wieder ein stetiger stochastischer Prozess und damit  $(Z_n)_{n \in \mathbb{N}}$  eine Folge von Zufallsvariablen in  $(C(\mathbb{R}), d)$ . Wünschenswert auch hier wäre die Gültigkeit folgender Implikation:

$$Z_n \xrightarrow{\mathcal{L}} Z \text{ in } (C(\mathbb{R}), d) \implies \arg \min_{t \in \mathbb{R}} Z_n(t) \xrightarrow{\mathcal{L}} \arg \min_{t \in \mathbb{R}} Z(t) \quad (*)$$



Dazu erforderlich ist das Konzept der **Verteilungskonvergenz** von Zufallsvariablen in metrischen Räumen, damit (\*) eine wohldefinierte Bedeutung erhält. Dies folgt später. Natürlich auch hier wieder das Problem:  $Z$  besitzt mit positiver Wahrscheinlichkeit mindestens 2. Minimalstellen. Und dann?

## A. Anhang

### A.1. Grundlagen, die man kennen sollen

TODO

**Satz A.1.1** (Maßkorrespondenzsatz) Sei  $X$  eine Zufallsvariable. Dann bestimmt das Maß eindeutig die Verteilung  $F$  von  $X$  und die Verteilung bestimmt eindeutig das Maß.

**Notation.**  $\int f(x) dx$  bedeutet man integriert bzgl. Maß  $Q$ , was durch  $F$  eindeutig festgelegt ist.

**Satz A.1.2** (Transformationsformel)

**Satz A.1.3** (Lebesgue / dominierte Konvergenz)

**Satz A.1.4** (Monotone Konvergenz)

**Satz A.1.5** (Gliwenko-Cantelli)